

MDA Assistant - Kiến Trúc & Tổng Quan

1. Giới thiệu chung

MDA Assistant là một trợ lý ảo AI thông minh được thiết kế và phát triển độc quyền bởi **Thanh Sang** (SangTranTamLy). Được tích hợp trực tiếp vào hệ sinh thái Zenith Workspace, MDA Assistant đóng vai trò là một cầu nối giao tiếp tương tác giữa người dùng và toàn bộ dữ liệu danh mục đầu tư (portfolio), kỹ năng, cũng như các dự án cá nhân của Sang.

Thay vì phải đọc những trang tài liệu dài dòng, người dùng có thể trò chuyện trực tiếp bằng ngôn ngữ tự nhiên để tìm hiểu về Thanh Sang, từ kiến thức chuyên môn Frontend/Backend cho đến khả năng biên tập Video (Post-Production).

2. Người sáng tạo

- Nhà phát triển: Thanh Sang
- Nghệ danh Code: SangTranTamLy
- Nghệ danh Media/Editor: Zenith
- Vai trò: Full-stack Developer & Motion Designer
- Mục tiêu tạo ra MDA: Thể hiện tư duy tích hợp hệ thống phức tạp (AI + Web) và cung cấp một trải nghiệm tương tác độc đáo cho nhà tuyển dụng hoặc đối tác muốn tìm hiểu về năng lực của mình.

3. Chức năng chính

- **Hỏi đáp thông minh (Q&A):** Cung cấp thông tin chính xác về các dự án công khai, các kỹ năng lập trình (React, TypeScript, Node.js...) và kỹ năng Media (After Effects, Premiere).
- **Phân luồng Deterministic:** Tự động nhận diện các câu hỏi mang tính chất giao tiếp cơ bản (chào hỏi, hỏi giờ, hỏi liên hệ) để phản hồi ngay lập tức (độ trễ ~0ms).
- **Bảo mật và Anti-Hallucination:** Tuyệt đối không tự bịa thông tin. Nếu dữ liệu không tồn tại trong hệ thống, MDA sẽ thẳng thắn từ chối trả lời để đảm bảo độ tin cậy.

4. Kiến trúc Hệ thống (How it works)

MDA Assistant không phải là một con bot gọi API ChatGPT thông thường. Nó là một hệ thống AI tự chủ (Sovereign AI) chạy hoàn toàn dựa trên các công nghệ tiên tiến:

A. Mô hình Ngôn ngữ Lớn (LLM)

- Trái tim của MDA là mô hình **Qwen 2.5 (3B parameters)** được chạy cục bộ thông qua **Ollama**. Điều này đảm bảo tốc độ phản hồi cực nhanh, không phụ thuộc vào Internet (nếu chạy local) và hoàn toàn bảo mật dữ liệu.

B. Thuật toán RAG (Retrieval-Augmented Generation)

Để AI biết về Thanh Sang, hệ thống sử dụng kiến trúc RAG:

1. **Data Ingestion:** Một cỗ máy (crawler) tự động chạy lên GitHub, kéo các file tài liệu `README.md` của các dự án về.
2. **Chunking & Embedding:** Dữ liệu văn bản được băm nhỏ và chuyển đổi thành dạng Vector 768 chiều bằng mô hình **nomic-embed-text**.
3. **Vector Database:** Các vector này được lưu trữ vào cơ sở dữ liệu **PostgreSQL** (thông qua Supabase) với phần mở rộng **pgvector**.
4. **Truy xuất (Retrieval):** Khi người dùng đặt câu hỏi, câu hỏi cũng được biến thành Vector. Database sẽ dùng toán học (Cosine Similarity) để tìm ra các

đoạn tài liệu liên quan nhất.

5. **Tổng hợp:** Các tài liệu này được "nhét" vào não của Qwen 2.5 cùng với một Prompt thép (System Prompt), ép buộc AI phải đọc tài liệu và trả lời người dùng.

C. Giao diện (Frontend)

- Được xây dựng bằng **React**, **Vite** và **Framer Motion** để tạo ra các hiệu ứng chuyển động mượt mà, kết hợp với công nghệ truyền dữ liệu thời gian thực **SSE (Server-Sent Events)** giúp AI có thể "gõ chữ" ngay lập tức trên màn hình thay vì phải chờ load toàn bộ câu trả lời.

5. Kết luận

MDA Assistant không chỉ là một công cụ trò chuyện, nó là minh chứng cho khả năng kết hợp hoàn hảo giữa Engineering (Thiết kế hệ thống, Xử lý dữ liệu, Tối ưu hóa API) và Product Design (Trải nghiệm người dùng) của Thanh Sang.